



Predictive IT Infrastructure Analytics

Deteccion temprana de incidentes en infraestructuras IT
mediante Machine Learning

Analisis · Transformacion · Modelado Predictivo

Autor: Ing. Randy Bonucci Martin

Problema y Objetivo del Proyecto

- Las infraestructuras IT generan metricas continuas: CPU, memoria, temperatura, latencia...
- Detectar fallos antes de que ocurran es critico para la disponibilidad del servicio
- El enfoque reactivo ya no es suficiente en entornos complejos

Objetivo General:

Desarrollar modelos predictivos que permitan la deteccion temprana de incidentes a partir de metricas de rendimiento del sistema, facilitando la monitorizacion proactiva y la reduccion de riesgos operativos.

El Dataset

IT System Performance & Resource Metrics

Característica	Valor
Registros	10 000
Variables originales	12 (todas numericas)
Valores nulos	0
Registros duplicados	0
Variable objetivo	status (0 = Normal, 1 = Incidente)

Distribucion de la variable objetivo:

Normal (0) : 9 903 registros (99.03 %)

Incidente (1) : 97 registros (0.97 %)

ATENCION: Fuerte desbalance de clases

- Comportamiento realista en entornos IT

(los fallos son eventos raros)

Hallazgos del Analisis Exploratorio

Correlacion con el estado del sistema (status):

Variable	Correlacion
system_pressure_score	0.174
memory_usage	0.140
cpu_utilization	0.136
temperature	0.117
context_switches	0.015
uptime	0.010

- Las variables mas relevantes: CPU, memoria y temperatura
- El indicador compuesto system_pressure_score supera
 - a cualquier variable individual
- Baja multicolinealidad entre variables -> favorable para modelado

Insights Clave del Analisis

1. CPU Level vs Estado del Sistema

Los 97 incidentes ocurren exclusivamente en nivel HIGH (>70 % CPU). ■ LOW y MEDIUM: 0 incidentes.

2. Temperature Level vs Estado del Sistema

Los 97 incidentes ocurren exclusivamente en nivel CRITICAL (>70 C). ■ NORMAL y WARNING: 0 incidentes.

3. Pressure Level vs Estado del Sistema

79 de 97 incidentes en nivel HIGH de presion. ■ 18 en MEDIUM. LOW: 0 incidentes.

Conclusion: Alta presion del sistema (CPU + temperatura) = alto riesgo de incidente

Feature Engineering

- Categorías: cpu_level, memory_level, latency_level, temperature_level
- Normalización Min-Max: 5 variables principales
- Indicador compuesto: system_pressure_score
- Clasificación: pressure_level (Low/Medium/High)
- Etiquetas: status_label (Normal/Incident)

Antes vs Despues:

	Original	Transformado
Variables	12	24
Registros	10 000	10 000

system_pressure_score =

promedio de 5 metricas normalizadas:

cpu_utilization_norm, memory_usage_norm,
network_latency_norm, temperature_norm,
power_consumption_norm

Modelos Predictivos Evaluados

- Regresion Logistica -> modelo base, interpretable
- Random Forest -> 200 arboles, class_weight='balanced'
- Red Neuronal MLP -> 2 capas ocultas (32, 16), escalado previo

Metricas de evaluacion (clase Incidente):

Modelo	Accuracy	Precision	Recall	F1-Score
Regresion Logistica	0.97	0.24	1.00	0.39
Random Forest	1.00	1.00	0.95	0.97
Red Neuronal MLP	1.00	0.81	0.68	0.74

Resultados - Random Forest (Modelo Seleccionado)

Matriz de Confusion sobre conjunto de prueba (2 000 registros):

	Predicho: Normal	Predicho: Incidente
Real: Normal	1 981 (VN)	0 (FP)
Real: Incidente	1 (FN)	18 (VP)

Leyenda:

VN = Real: Normal, Predicho: Normal (acierto)

VP = Real: Incidente, Predicho: Incidente (acierto)

FN = Real: Incidente, Predicho: Normal (error - falso negativo)

FP = Real: Normal, Predicho: Incidente (error - falso positivo)

Interpretacion:

- Detecto 18 de 19 incidentes reales (Recall = 95 %)
- Cero falsos positivos (Precision = 100 %)
- Solo 1 incidente no detectado (falso negativo)
- F1-Score = 0.97 - excelente equilibrio

Conclusiones

1. Preparación y Transformación de los Datos

Durante las fases iniciales del proyecto se realizó la exploración, validación y preparación del dataset de métricas de infraestructura IT. El conjunto de datos no presentó valores nulos ni registros duplicados, lo que permitió centrar el trabajo en la transformación y enriquecimiento de las variables. Posteriormente se aplicaron técnicas de normalización, categorización e ingeniería de características con el objetivo de facilitar el análisis y mejorar la capacidad predictiva de los modelos.

2. Análisis Exploratorio de Datos

El análisis exploratorio permitió comprender el comportamiento de las principales métricas operativas de la infraestructura, incluyendo utilización de CPU, consumo de memoria, operaciones de disco, latencia de red, temperatura y consumo energético. Las visualizaciones mostraron distribuciones relativamente estables en la mayoría de las variables, así como la existencia de relaciones entre determinados indicadores operativos y el estado registrado del sistema. Asimismo, se observó un fuerte desbalance entre registros normales e incidencias, siendo los estados normales la gran mayoría de las observaciones disponibles en el dataset.

3. Modelo Predictivo

Se entrenaron y evaluaron diferentes algoritmos de Machine Learning para predecir posibles incidencias dentro de la infraestructura tecnológica. La comparación de métricas permitió identificar al modelo Random Forest como la alternativa con mejor rendimiento general para este problema de clasificación.

4. Resultados Obtenidos

El modelo fue capaz de identificar registros asociados a posibles incidencias dentro del conjunto de datos analizado. Las métricas obtenidas durante la evaluación, junto con la matriz de confusión y el análisis de predicciones, permitieron validar el comportamiento del modelo y comprobar su capacidad para diferenciar entre estados normales y situaciones potencialmente anómalas.

5. Aplicación Práctica

El dashboard implementado permite visualizar indicadores operativos, revisar el comportamiento del modelo predictivo y consultar las incidencias detectadas, proporcionando una base para futuras soluciones orientadas a observabilidad, soporte técnico, operaciones IT o detección temprana de anomalías.

6. Trabajo Futuro

Como posibles líneas de mejora se plantea la incorporación de nuevos datasets con una mayor representación de incidencias reales, la evaluación de técnicas adicionales de balanceo de clases, la comparación con nuevos algoritmos predictivos y la integración de mecanismos de monitorización en tiempo real para la detección automática de anomalías.

Recomendaciones

- Implementar monitorizacion proactiva de CPU, memoria y temperatura
- Establecer umbrales de alerta para niveles HIGH de CPU y CRITICAL de temperatura
- Utilizar el modelo Random Forest como herramienta de apoyo a la operacion IT
- Incorporar nuevas fuentes de datos: logs, almacenamiento, trafico de red
- Actualizar y reentrenar los modelos periodicamente
- Explorar tecnicas adicionales de balanceo para mejorar deteccion de eventos raros
- Validar los resultados en entornos reales de produccion antes del despliegue



Gracias

Predictive IT Infrastructure Analytics

?Preguntas?